

МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
имени М.В. Ломоносова

Факультет вычислительной математики и кибернетики

Учебный курс
«ТЕХНОЛОГИЧЕСКИЙ ПРАКТИКУМ»

Отчет
о выполненном задании

студента 316 учебной группы факультета ВМК МГУ
Шевченко Глеба

Москва
2025

Содержание

1	Описание исходных данных	3
2	Аппроксимация распределений данных с помощью ядерных оценок	5
2.1	Теория KDE	5
2.2	Результаты	6
2.3	Выводы по форме распределений	8
3	Анализ данных с помощью cdplot, dotchart, boxplot и stripchart	9
3.1	Теория	9
3.2	Построение графиков для исходных данных	10
3.3	Выводы по результатам визуализации	15
4	Критерии Граббса и Q-тест Диксона	16
4.1	Теория	16
4.2	Применение к данным	17
4.3	Выводы	21
5	Заполнение пропусков в данных	21
5.1	Общие сведения	21
5.2	Применение к данным	21
5.3	Выводы	23
6	Анализ нормального распределения	24
6.1	Теоретические сведения	24
6.2	Моделирование нормальных выборок	25
6.3	Результаты тестов на нормальность	26
6.4	Выводы	27
6.5	Проверка нормальности в R	27
7	Анализ данных с помощью графиков квантилей, метода огибающих и стандартных критериев нормальности	30
7.1	Выборки и графический анализ	30
7.2	Результаты критериев нормальности	32
7.3	Выводы	32
8	Проверка гипотез	33
8.1	Теория	33
8.2	t-критерий	33
8.3	Критерий Уилкоксона-Манна-Уитни	35
8.4	Проверка равенства дисперсий	35
8.5	Выводы	36
9	Корреляционные взаимосвязи	37
9.1	Теория	37
9.2	Матрицы корреляций	37
9.3	Наиболее сильные взаимосвязи	38
9.4	Выводы	39

10	Метод χ^2, точный тест Фишера, тест МакНемара и критерий Кохрана–Мантеля–Хензеля	40
10.1	Теория	40
10.2	Тест χ^2	40
10.3	Точный тест Фишер	41
10.4	Тест МакНемара: отклики на кампании 1 и 2	42
10.5	Критерий Кохрана–Мантеля–Хензеля	42
10.6	Выводы	43
11	Мультиколлинеарность в данных	43
11.1	Теория	43
11.2	Результаты	43
11.3	Выводы	44
12	Дисперсионный анализ	45
12.1	Теория	45
12.2	Результаты	45
13	Регрессионные модели (в том числе нелинейные)	47
13.1	Теория	47
13.2	Подготовка данных и постановка задачи	47
13.3	Результаты моделирования	48
13.4	Выводы	48
	Список литературы	50

1 Описание исходных данных

В качестве исходных данных используется маркетинговый датасет компании розничной торговли. Набор содержит сведения о клиентах и их покупательском поведении: социально-демографические характеристики, дату начала взаимодействия с компанией, показатели давности последней покупки, а также агрегированные расходы по основным товарным категориям и количество покупок по различным категориям.

Всего в датасете содержится 2240 наблюдений (клиентов) и 20 признаков. Из них 3 признака являются категориальными (*Education*, *Marital_Status*, *Dt_Customer*), остальные числовыми.

Уровень образования представлен пятью категориями: *Graduation*, *PhD*, *Master*, *Basic*, *2n Cycle*. Около половины клиентов имеют образование уровня *Graduation*, заметные доли приходятся на *PhD* и *Master*. По признаку семейного положения (*Marital_Status*) доминируют состояния *Married*, *Together* и *Single*; меньшая часть клиентов находится в статусе *Divorced* или *Widow*.

Числовые признаки описывают возраст (через год рождения *Year_Birth*), количество детей (*Kidhome*, *Teenhome*), уровень дохода (*Income*), давность последней покупки (*Recency*), а также суммарные расходы за последние два года по различным категориям товаров (*MntWines*, *MntFruits*, *MntMeatProducts*, *MntFishProducts*, *MntSweetProducts*, *MntGoldProds*) и количество покупок по каналам (*NumDealsPurchases*, *NumWebPurchases*, *NumCatalogPurchases*, *NumStorePurchases*, *NumWebVisitsMonth*). (*NumWebVisitsMonth*).

Общее описание признаков приведено в таблице 1.

Признак	Тип	Описание
ID	числовой	Уникальный идентификатор клиента
Year_Birth	числовой	Год рождения клиента
Education	категориальный	Уровень образования клиента
Marital_Status	категориальный	Семейное положение клиента
Income	числовой	Годовой доход домохозяйства
Kidhome	числовой	Количество маленьких детей в домохозяйстве
Teenhome	числовой	Количество подростков в домохозяйстве
Dt_Customer	дата	Дата начала взаимодействия клиента с компанией
Recency	числовой	Число дней с момента последней покупки
MntWines	числовой	Расходы на вино за последние два года
MntFruits	числовой	Расходы на фрукты за последние два года
MntMeatProducts	числовой	Расходы на мясные продукты за последние два года
MntFishProducts	числовой	Расходы на рыбную продукцию за последние два года
MntSweetProducts	числовой	Расходы на сладости за последние два года
MntGoldProds	числовой	Расходы на ювелирные изделия за последние два года
NumDealsPurchases	числовой	Количество покупок по промо-акциям и скидкам
NumWebPurchases	числовой	Количество покупок через веб-сайт
NumCatalogPurchases	числовой	Количество покупок по каталогу
NumStorePurchases	числовой	Количество покупок в розничных магазинах
NumWebVisitsMonth	числовой	Количество посещений веб-сайта за последний месяц

Таблица 1: Описание признаков исходного набора данных.

Признак	Среднее	Минимум	Максимум	Пропусков
ID	5592.16	0.00	11191.00	0
Year_Birth	1968.81	1893.00	1996.00	0
Income	52247.25	1730.00	666666.00	24
Kidhome	0.44	0.00	2.00	0
Teenhome	0.51	0.00	2.00	0
Recency	49.11	0.00	99.00	0
MntWines	303.94	0.00	1493.00	0
MntFruits	26.30	0.00	199.00	0
MntMeatProducts	166.95	0.00	1725.00	0
MntFishProducts	37.53	0.00	259.00	0
MntSweetProducts	27.06	0.00	263.00	0
MntGoldProds	44.02	0.00	362.00	0
NumDealsPurchases	2.33	0.00	15.00	0
NumWebPurchases	4.08	0.00	27.00	0
NumCatalogPurchases	2.66	0.00	28.00	0
NumStorePurchases	5.79	0.00	13.00	0
NumWebVisitsMonth	5.32	0.00	20.00	0

Таблица 2: Краткие статистические характеристики числовых признаков.

Год рождения клиентов варьируется от 1893 до 1996 года, средний год рождения составляет около 1969 года. Таким образом, в выборке представлены в основном взрослые клиенты среднего возраста. В среднем в домохозяйстве менее одного ребёнка: значения `Kidhome` и `Teenhome` не превышают 2.

Средний годовой доход клиентов составляет порядка 52 тыс. условных единиц при минимальном значении 1730 и максимальном 666 666. Признак давности последней покупки (`Recency`) принимает значения от 0 до 99 дней, среднее значение около 49 дней.

Расходы по товарным категориям сильно варьируются: например, средние расходы на вино (`MntWines`) составляют около 304 единиц при максимальном значении 1493, расходы на мясные продукты (`MntMeatProducts`) — около 167 единиц при максимуме 1725. Количество покупок по каналам (`NumWebPurchases`, `NumCatalogPurchases`, `NumStorePurchases`) и число визитов на сайт за месяц (`NumWebVisitsMonth`) также демонстрируют существенную изменчивость.

2 Аппроксимация распределений данных с помощью ядерных оценок

2.1 Теория KDE

На практике истинная плотность распределения, как правило, неизвестна, и её необходимо оценить по выборке. Один из наиболее распространённых непараметрических подходов для этой задачи *ядерная оценка плотности* (Kernel Density Estimation, KDE).

Пусть имеется выборка независимых наблюдений

$$x_1, x_2, \dots, x_n \sim F,$$

где F — неизвестное распределение с плотностью $f(x)$. Ядерная оценка плотности в

точке x определяется как

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right),$$

где $K(\cdot)$ — *ядерная функция*, а $h > 0$ — параметр сглаживания (ширина окна, bandwidth).

Ядро $K(u)$ представляет собой неотрицательную, интегрируемую функцию, удовлетворяющую условию $\int_{-\infty}^{+\infty} K(u) du = 1$. Типичные примеры ядер — гауссовское ядро

$$K(u) = \frac{1}{\sqrt{2\pi}} e^{-u^2/2},$$

прямоугольное и др. Влияние выбора конкретной формы ядра, как правило, невелико; наибольшее значение имеет выбор параметра h .

Параметр сглаживания h определяет компромисс между смещением и дисперсией оценки: при слишком малом h оценка получается “рваной” и чувствительной к шуму (переобучение), при слишком большом h — чрезмерно сглаженной и не отражающей реальные особенности распределения (недообучение).

2.2 Результаты

Перед построением ядерных оценок плотности для всех числовых признаков были построены гистограммы распределения, рисунок 1. Гистограммы позволяют увидеть базовую форму эмпирических распределений: наличие асимметрии, тяжёлых хвостов и возможных выбросов. Уже на этом этапе видно, что большинство признаков существенно отклоняются от нормального распределения.

В рамках данной работы для всех числовых признаков датасета: `Year_Birth`, `Income`, `Kidhome`, `Teenhome`, `Recency`, `MntWines`, `MntFruits`, `MntMeatProducts`, `MntFishProducts`, `MntSweetProducts`, `MntGoldProds`, `NumDealsPurchases`, `NumWebPurchases`, `NumCatalogPurchases`, `NumStorePurchases`, `NumWebVisitsMonth` были построены ядерные оценки плотности распределения.

Ядерные оценки были получены двумя способами:

- на языке Python с использованием стандартных средств визуализации (по умолчанию используется гауссовское ядро и автоматический выбор ширины окна);
- на языке R с аналогичными настройками (гауссовское ядро и автоматический подбор параметра сглаживания).

Результаты представлены на рисунках 2 и 3.




Рис. 1: Гистограммы числовых признаков датасета.




Рис. 2: Ядерные оценки плотностей числовых признаков (реализация на Python).




Рис. 3: Ядерные оценки плотностей числовых признаков (реализация на R).

Формы кривых для соответствующих признаков в Python и R практически совпадают, что подтверждает корректность реализации метода.

2.3 Выводы по форме распределений

Анализ ядерных оценок позволяет сделать следующие наблюдения.

- Признак **Year_Birth** имеет одномодальное распределение с максимумом в области примерно 1965–1975 годов. Это соответствует выборке преимущественно из клиентов среднего возраста; крайние значения (очень молодые и очень пожилые клиенты) представлены слабо.
- Распределение дохода **Income** сильно правосторонне асимметрично: большая часть клиентов сосредоточена в интервале умеренных доходов, при этом имеется длинный правый хвост, соответствующий небольшому количеству клиентов с очень высокими доходами. Это указывает на наличие выбросов и говорит о целесообразности логарифмирования дохода или использования робастных методов.
- Признак давности последней покупки **Recency** распределён примерно близко к равномерному на отрезке 0–100 дней с несколькими локальными максимумами, то есть в выборке присутствуют как “свежие” клиенты, так и клиенты, давно не совершавшие покупок.

- Все переменные, описывающие расходы по товарным категориям (`MntWines`, `MntFruits`, `MntMeatProducts`, `MntFishProducts`, `MntSweetProducts`, `MntGoldProds`), характеризуются выраженной правосторонней асимметрией: для большинства клиентов траты по соответствующим категориям невелики, тогда как небольшая доля демонстрирует существенно более высокие расходы. Наиболее сглаженное распределение наблюдается для `MntWines`, что отражает наличие группы клиентов с регулярными покупками вина.
- Похожие по форме, правосторонне асимметричные распределения имеют количественные показатели активности: `NumDealsPurchases`, `NumWebPurchases`, `NumCatalogPurchases`, `NumStorePurchases`. Большинство клиентов совершает небольшое число покупок, интенсивные покупатели встречаются значительно реже.
- Признак `NumWebVisitsMonth` имеет максимум в области 5–7 посещений, после чего плотность постепенно убывает. Это говорит о наличии основной массы “умеренно активных” пользователей сайта и небольшой доли очень частых посетителей.

В целом, ядерные оценки показывают, что большинство количественных признаков в рассматриваемом датасете существенно отклоняются от нормального распределения: характерны сильная правосторонняя асимметрия и тяжёлые хвосты.

3 Анализ данных с помощью `cdplot`, `dotchart`, `boxplot` и `stripchart`

3.1 Теория

Удобно использовать специальные графики, позволяющие визуально оценить изменение распределения количественного признака в зависимости от категориального и наоборот. В данной работе используются следующие инструменты: `cdplot`, `dotchart`, `boxplot` и `stripchart`.

CDPLOT. График типа CDPLOT (conditional density plot) отображает условные распределения категориальной переменной Y при фиксированных значениях количественной переменной X . По сути, это визуализация оценок вероятностей

$$\hat{p}_k(x) = P(Y = k \mid X = x), \quad k = 1, \dots, K,$$

полученных с помощью ядерного сглаживания. При фиксированном x сумма высот всех “слоёв” графика равна 1, поэтому он показывает, как меняется доля каждой категории k при переходе от малых к большим значениям X .

Практически CDPLOT строится как набор ядерных оценок плотностей для каждой категории с последующей нормировкой:

$$\hat{p}_k(x) = \frac{\sum_{i:y_i=k} K\left(\frac{x-x_i}{h}\right)}{\sum_{j=1}^K \sum_{i:y_i=j} K\left(\frac{x-x_i}{h}\right)},$$

где $K(\cdot)$ — ядро, h — параметр сглаживания.

Dotchart. Dotchart (dot plot) — одномерная диаграмма точек. dotchart строят по агрегированным значениям (например, средним по группам): каждая категория изображается точкой на числовой оси, что позволяет наглядно сравнить уровни показателя между группами.

Boxplot. Boxplot (ящик с усами) визуализирует основные характеристики распределения: медиану, первый и третий квартили, межквартильный размах и потенциальные выбросы. “Ящик” ограничивает интервал между первым и третьим квартилями, внутри ящика проводится линия медианы. “Усы” обычно тянутся до последнего наблюдения, которое не выходит за пределы $[Q_1 - 1.5 \cdot IQR, Q_3 + 1.5 \cdot IQR]$, где $IQR = Q_3 - Q_1$ — межквартильный размах; более дальние точки считаются выбросами. При наличии категориальной переменной строится набор boxplot-ов для каждой категории, что позволяет сравнивать распределения между группами.

Stripchart. Stripchart (strip plot) — это набор точек, расположенных вдоль числовой оси для каждой категории. Каждая точка соответствует одному наблюдению. Чтобы точки не накладывались, часто используется небольшой “jitter” (случайное смещение) в ортогональном направлении. Stripchart хорошо показывает форму распределения внутри каждой группы, плотность точек и возможные кластеры.

3.2 Построение графиков для исходных данных

Для изучения связей между признаками из рассматриваемого датасета были построены следующие графики (как в среде Python, так и в R):

- CDPLLOT зависимости уровня образования `Education` от расходов на вино `MntWines`;
- dotchart средних расходов на вино `MntWines` по уровням образования;
- boxplot распределения дохода `Income` по семейному статусу `Marital_Status`;
- stripchart распределения давности последней покупки `Recency` по семейному статусу.

Ниже приведены примеры соответствующих визуализаций (сначала — реализация в Python, потом — в R).




Рис. 4: CDPLOT: условное распределение уровня образования при разных значениях расходов на вино (Python).




Рис. 5: CDPLOT: условное распределение уровня образования при разных значениях расходов на вино (R).




Рис. 6: Dotchart: средние траты на вино по уровням образования (Python).




Рис. 7: Dotchart: средние траты на вино по уровням образования (R).




Рис. 8: Boxplot: распределение дохода по семейному статусу (Python).




Рис. 9: Boxplot: распределение дохода по семейному статусу (R).




Рис. 10: Stripchart: распределение давности последней покупки по семейному статусу (Python).




Рис. 11: Stripchart: распределение давности последней покупки по семейному статусу (R).

3.3 Выводы по результатам визуализации

Анализ совместных графиков даёт следующие наблюдения.

- На CDPLLOT (рис. 4, 5) видно, что при малых значениях **MntWines** доминируют клиенты с образованием уровня **Basic** и **Graduation**, тогда как доля **Master** и особенно **PhD** невелика. По мере роста расходов на вино доля клиентов с высшим и учёной степенью существенно увеличивается, а категории **Basic** и **2n Cycle** практически исчезают. Это говорит о положительной связи между уровнем образования и склонностью тратить больше на вино.
- Dotchart средних трат на вино (рис. 6, 7) подтверждает этот вывод численно: минимальные средние расходы наблюдаются у клиентов с базовым образованием (**Basic**), затем идут **2n Cycle**, **Graduation**, выше **Master**, и максимальные значения у группы **PhD**. Графики в Python и R дают одинаковый порядок уровней.
- Boxplot дохода по семейному статусу (рис. 8, 9) показывает, что для основных категорий (**Single**, **Married**, **Together**, **Divorced**, **Widow**) распределения доходов в целом близки: медианы и межквартильные размахи сопоставимы. Для некоторых редких статусов (**Alone**, **Absurd**, **YOLO**) разброс и уровень дохода отличаются, однако это, скорее всего, связано с небольшим количеством наблюдений

в этих группах. Наличие выбросов в верхней части boxplot-ов подтверждает, что часть клиентов имеет существенно более высокие доходы по сравнению с основной массой.

- Stripchart Recency по семейному статусу (рис. 10, 11) показывает, что для основных статусов точки практически равномерно заполняют диапазон от 0 до 100 дней. То есть существенных различий в давности последней покупки между группами Single, Married, Together, Divorced, Widow не наблюдается. Небольшие отличия у редких категорий (Alone, Absurd, YOLO) опять же, скорее всего, обусловлены малым числом клиентов.

В целом, рассмотренные графики демонстрируют:

- чёткую зависимость расходов на вино от уровня образования;
- относительно слабую зависимость дохода и давности последней покупки от семейного статуса;
- соответствие результатов, полученных в Python и R.

4 Критерии Граббса и Q-тест Диксона

4.1 Теория

Важно выявить аномальные наблюдения (выбросы), которые сильно отличаются от основной массы данных и могут искажать результаты оценивания и проверки гипотез. Существуют специальные статистические критерии для их обнаружения. В данной работе рассматриваются критерий Граббса и Q-тест Диксона.

Критерий Граббса. Критерий Граббса (Grubbs' test) применяется для проверки гипотезы о наличии *одного* выброса в однородной выборке, для которой можно предполагать нормальное распределение. Пусть имеется выборка $x_1, \dots, x_n$ из нормального распределения $\mathcal{N}(\mu, \sigma^2)$. Проверяется гипотеза

H_0 : выбросов нет против H_1 : в выборке имеется одно выбросное наблюдение.

Двусторонний критерий Граббса использует статистику

$$G = \frac{\max_i |x_i - \bar{x}|}{s},$$

где $\bar{x}$ — выборочное среднее, s — несмещённая выборочная дисперсия.

Критическое значение G_{crit} зависит от объёма выборки n и уровня значимости α . Если $G > G_{\text{crit}}$, нулевая гипотеза отклоняется и наблюдение с максимальным отклонением считается выбросом. В противном случае статистически значимых выбросов не обнаруживается. Предполагается, что проверяется наличие не более одного выброса.

Q-тест Диксона. Q-тест Диксона (Dixon's Q test) также предназначен для выявления одиночного выброса, но в первую очередь для небольших выборок (обычно $3 \leq n \leq 30$), и также предполагает близость распределения к нормальному.

Пусть отсортированная выборка имеет вид

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}.$$

Для проверки подозрения на выброс снизу ($x_{(1)}$) используется статистика

$$Q_{\min} = \frac{x_{(2)} - x_{(1)}}{x_{(n)} - x_{(1)}},$$

для выброса сверху ($x_{(n)}$) — аналогичная статистика

$$Q_{\max} = \frac{x_{(n)} - x_{(n-1)}}{x_{(n)} - x_{(1)}}.$$

Если $Q > Q_{\text{crit}}$ (по таблице критических значений для данного n и уровня α), наблюдение признаётся выбросом, иначе статистически значимого выброса не обнаружено.

4.2 Применение к данным

Так как оба рассматриваемых критерия предполагают близость распределения к нормальному, применять их ко всем числовым признакам датасета некорректно: большинство распределений (доход, траты, количество покупок) сильно асимметричны. Чтобы выполнить предпосылки методов, была выбрана более однородная подвыборка: доход клиентов с базовым образованием,

Income | Education = Basic.

Для этой группы были отобраны все наблюдения без пропусков. Проверка нормальности по критерию Шапиро–Уилка дала $p\text{-value} \approx 0.206$, что больше 0.05, поэтому нулевая гипотеза о нормальном распределении не отвергается. Соответствующие QQ-графики и boxplot показаны на рис. 12 и 13: визуально распределение также близко к нормальному, явно выраженных выбросов не наблюдается.




Рис. 12: QQ-график и boxplot для выборки Income при Education=Basic (исходные данные).



Рис. 13: Иллюстрация для Q-теста Диксона на исходной подвыборке (без искусственного выброса).

Критерий Граббса на исходной выборке. Для исходной подвыборки был вычислен двухсторонний критерий Граббса. Получены значения

$$G = 2.27, \quad G_{\text{crit}} \approx 3.16, \quad \text{решение: выброс не найден.}$$

То есть максимальное по модулю отклонение наблюдения от среднего не превышает критического порога, и формального статистического основания считать какое-либо наблюдение выбросом нет, что согласуется с визуальным анализом boxplot на рис. 12.

Чтобы продемонстрировать работу критерия на данных с явным выбросом, в выборку был добавлен *синтетический* объект с существенно завышенным доходом. Повторное применение критерия Граббса дало

$$G = 4.58, \quad G_{\text{crit}} \approx 3.17, \quad \text{решение: выброс найден.}$$

Так как статистика G превысила критическое значение, добавленное наблюдение корректно выявляется как выброс. Соответствующий график показан на рис. 14.




Рис. 14: QQ-график и boxplot для выборки Income при Education=Basic с добавленным синтетическим выбросом.

Так же посмотрим на гистограмму дохода для группы клиентов с базовым образованием (см. рисунок 15) видно, что исходная выборка имеет примерно колоколообразную форму, без явно изолированных крайних значений. После добавления синтетического наблюдения появляется одиночный столбец в правой части гистограммы, соответствующий существенно завышенному доходу и отчётливо отделённый от основной массы данных. Именно это наблюдение и выявляется критерием Граббса как выброс.




Рис. 15: Гистограммы дохода Income в группе Education=Basic до и после добавления синтетического выброса.

Q-тест Диксона. Так как Q-тест Диксона применим для сравнительно небольших выборок, из той же подвыборки Income при Education=Basic была случайным образом сформирована подвыборка объёма $n = 30$. Критерий Шапиро–Уилка для неё дал $p\text{-value} \approx 0.199 > 0.05$, то есть предположение о нормальности также не отвергается.

Для исходной подвыборки из 30 наблюдений значения статистики Q-теста и критического порога оказались равны

$$Q = 0.069, \quad Q_{\text{crit}} = 0.263, \quad \text{решение: выброс не найден (граница снизу)}.$$

Таким образом, никаких крайних наблюдений, выделяющихся по критерию Диксона, в этих данных нет.

Далее в выборку размера $n = 30$ было добавлено синтетическое наблюдение с завышенным доходом (аналогично эксперименту с критерием Граббса). Для обновлённой подвыборки получены значения

$$Q = 0.566, \quad Q_{\text{crit}} = 0.260, \quad \text{решение: выброс найден (граница сверху)}.$$

Поскольку Q существенно превосходит критический уровень, тест корректно идентифицирует добавленное наблюдение как выброс. Иллюстрации для обеих ситуаций приведены на рис. 16 и 17.




Рис. 16: Q-тест Диксона на подвыборке с синтетическим выбросом: выброс обнаружен.




Рис. 17: Сравнение результатов Q-теста для исходной и модифицированной выборки.

Аналогичную картину дают гистограммы подвыборки объёма $n = 30$ (смотреть рис. 18), использованной для Q-теста Диксона. В исходной подвыборке значения дохода сосредоточены в сравнительно узком диапазоне, распределение близко к симметричному и крайние значения отсутствуют. После добавления синтетического наблюдения в правый хвост распределения появляется отдельный столбец, существенно удалённый от основной группы. При этом статистика Q превышает критический уровень, и тест Диксона корректно классифицирует добавленное наблюдение как выброс.




Рис. 18: Гистограммы подвыборки Income (Education=Basic, n=30) до и после добавления синтетического выброса.

4.3 Выводы

- Критерий Граббса и Q-тест Диксона применимы только при условии приближенной нормальности распределения и при наличии не более одного выброса. Поэтому для проверки выбросов была выбрана специально подобранная подвыборка Income при Education=Basic, для которой проверка Шапиро–Уилка не отвергла нормальность.
- На реальных данных этой группы формальных выбросов не обнаружено ни по критерию Граббса, ни по Q-тесту Диксона, что подтверждается и графическим анализом (QQ-плоты и boxplot).

5 Заполнение пропусков в данных

5.1 Общие сведения

Простейшие подходы импутации основаны на замене пропусков константой (средним или медианой по столбцу), однако они игнорируют взаимосвязи между признаками и могут существенно исказить распределение данных. Более продвинутые методы, такие как KNN-импутация и итеративная (многомерная) импутация, используют информацию сразу о нескольких признаках и лучше восстанавливают структуру данных.

В данной работе для демонстрации сравнения методов заполнения пропусков рассматриваются четыре подхода:

1. замена на среднее значение по столбцу (**mean**);
2. замена на медиану (**median**);
3. KNN-импутация замена на среднее значение по ближайшим соседям в пространстве признаков (**knn**);
4. итеративная импутация, когда каждый признак последовательно регрессируется на остальные.

5.2 Применение к данным

Чтобы объективно оценить качество методов, пропуски были сгенерированы искусственно. Из полного датасета случайным образом было скрыто около 10% значений

в трёх числовых столбцах: `Income`, `MntWines`, `Recency`. Пример фрагмента данных после внесения пропусков:

Индекс	Income	MntWines	Recency
0	58138.0	635.0	58.0
1	46344.0	NaN	38.0
2	71613.0	426.0	26.0
3	26646.0	11.0	26.0
4	NaN	173.0	94.0

Истинные (скрытые) значения для этих позиций были сохранены отдельно и использовались как “тестовый набор” для оценки точности восстановления. Для каждой из четырёх стратегий импутации были рассчитаны две метрики по всем трём числовым признакам: среднее абсолютное отклонение (MAE) и корень из средней квадратической ошибки (RMSE). Сводка результатов приведена в таблице 3.

Метод	MAE	RMSE
mean	6431.94	7511.38
median	6444.05	7535.86
knn	7310.23	13086.98
iter	4431.24	5986.12

Таблица 3: Сравнение методов импутации по MAE и RMSE (оцениваются только скрытые значения).

Для наглядности на рис. 19–21 показано восстановление скрытых значений в отдельных признаках: истинные значения отмечены точками, а линии соответствуют различным методам импутации.




Рис. 19: Восстановление скрытых значений признака `Recency` разными методами импутации.



Рис. 20: Восстановление скрытых значений признака `MntWines`.



Рис. 21: Восстановление скрытых значений признака `Income`.

5.3 Выводы

Полученные результаты позволяют сделать несколько выводов.

- Простые одномерные методы (среднее и медиана) дают близкое качество: $MAE \approx 6,4 \cdot 10^3$, $RMSE \approx 7,5 \cdot 10^3$. Они не учитывают связи между признаками. Это хорошо видно на рисунках: линии `mean` и `median` практически горизонтальны и плохо описывают экстремальные значения.
- KNN-импутация использует информацию о соседних объектах и теоретически должна лучше восстанавливать локальную структуру данных. Однако в рассматриваемом датасете, где признаки сильно вариативны и присутствуют выбросы, качество KNN оказалось хуже.
- Итеративная многомерная импутация (`iter`) показала наилучшую точность: MAE снизился до $\approx 4,4 \cdot 10^3$, а $RMSE$ — до $\approx 6,0 \cdot 10^3$. Этот метод использует взаимосвязи между признаками и по сути строит регрессионную модель для каждого столбца, что позволяет лучше восстанавливать как значения. На

рисунках линии `iter` заметно ближе к истинным точкам, чем у остальных методов.

6 Анализ нормального распределения

6.1 Теоретические сведения

Нормальное распределение $\mathcal{N}(\mu, \sigma^2)$. Его плотность имеет вид

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right),$$

а функция распределения (CDF) $F(x)$ не имеет простого аналитического выражения и вычисляется численно.

Проверяя гипотезу нормальности для выборки $x_1, \dots, x_n$, удобно использовать как графические методы, так и формальные статистические тесты.

Эмпирическая функция распределения. Эмпирическая функция распределения (empirical distribution function, EDF) определяется как

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{x_i \leq x\}.$$

Если выборка получена из нормального распределения, то график $\hat{F}_n(x)$ должен хорошо аппроксимировать теоретическую функцию распределения $F(x)$ при некоторых параметрах μ, σ . Визуальное сравнение EDF и CDF позволяет оценить, насколько выборка “похожа” на нормальную.

QQ-график и доверительная огибающая. QQ-график (quantile–quantile plot) строится так: упорядочиваем выборку $x_{(1)} \leq \dots \leq x_{(n)}$ и сопоставляем ей теоретические квантильные уровни q_i нормального распределения (например, $q_i = F^{-1}\left(\frac{i-0.5}{n}\right)$). Если данные имеют нормальное распределение, точки $(q_i, x_{(i)})$ должны лежать примерно на прямой линии.

Также можно построить *доверительную огибающую*: многократно моделировать выборки из нормального распределения того же объёма, строить для них QQ-графики и по каждой теоретической координате q_i брать, например, 2.5%- и 97.5%-квантили. Полученная область служит 95%-й огибающей; если большинство точек реальной выборки лежит внутри неё, грубых отклонений от нормальности не наблюдается.

Тесты на нормальность. В работе используются несколько критериев:

- критерий Шапиро–Уилка (Shapiro–Wilk) — хорошо работает на малых выборках;
- критерий Андерсона–Дарлинга (Anderson–Darling) — учитывает поведение в хвостах распределения;
- критерий Крамера–фон Мизеса (Cramér–von Mises);
- критерий Колмогорова–Смирнова (KS) для нормального распределения с заданными μ, σ ;

- тест Лиллиефорса (модификация KS с поправкой на оценку параметров);
- критерий Шапиро–Франсиса (Shapiro–Francis) — модификация Шапиро–Уилка.

Во всех тестах нулевая гипотеза H_0 формулируется как «данные получены из нормального распределения». Малое значение p -значения ($p < 0,05$) приводит к отклонению H_0 , большие значения p -значения означают отсутствие статистических оснований отвергать нормальность.

6.2 Моделирование нормальных выборок

Для иллюстрации работы графических и формальных методов нормальности были сгенерированы четыре выборки из нормального распределения в Python:

- две “малые” выборки объёма $n_{\text{small}} = 50$;
- две “умеренно большие” выборки объёма $n_{\text{mod}} = 2000$;

с параметрами

$$(\mu, \sigma) \in \{(0, 1), (10, 2)\}.$$

Код генерации (с фиксированным генератором случайных чисел) имел вид:

`small_mu0_sd1, small_mu10_sd2` ($n = 50$), `mod_mu0_sd1, mod_mu10_sd2` ($n = 2000$).

Для каждой выборки были построены:

- эмпирическая функция распределения с наложенной CDF нормального распределения с подогнанными параметрами $(\hat{\mu}, \hat{\sigma})$;
- QQ-график с 95%-й доверительной огибающей.

Ниже приведены примеры полученных графиков (для краткости пары графиков EDF/QQ показаны для каждой выборки).




Рис. 22: EDF и QQ-график для выборки `small_mu0_sd1` ($n = 50$, $\mu \approx 0$, $\sigma \approx 1$).




Рис. 23: EDF и QQ-график для выборки `small_mu10_sd2` ($n = 50$, $\mu \approx 10$, $\sigma \approx 2$).




Рис. 24: EDF и QQ-график для выборки `mod_mu0_sd1` ($n = 2000$, $\mu \approx 0$, $\sigma \approx 1$).




Рис. 25: EDF и QQ-график для выборки `mod_mu10_sd2` ($n = 2000$, $\mu \approx 10$, $\sigma \approx 2$).

6.3 Результаты тестов на нормальность

Для всех четырёх выборок были вычислены значения p -значений нескольких тестов нормальности. Сводка приведена в таблице 4.

Выборка	n	Shapiro–Wilk p	AD stat	CvM p	KS p (fit)	Lilliefors p	SF W'	SF p
small_mu0_sd1	50	0.730	0.316	0.251	0.968	0.827	0.979	0.424
small_mu10_sd2	50	0.299	0.472	$5.2 \cdot 10^{-10}$	0.664	0.240	0.978	0.393
mod_mu0_sd1	2000	0.484	0.660	0.049	0.530	0.134	0.999	0.529
mod_mu10_sd2	2000	0.402	0.180	$1.9 \cdot 10^{-7}$	0.998	0.978	0.999	0.589

Таблица 4: Результаты тестов на нормальность для сгенерированных выборок.

Значения критерия Андерсона–Дарлинга (столбец AD stat) во всех случаях относительно невелики и ниже типичных критических значений для уровня значимости 0,05, поэтому этот тест нормальность не отвергает. Критерии Шапиро–Уилка, Колмогорова–Смирнова (с подгонкой параметров), Лиллиефорса и Шапиро–Франсиса во всех четырёх случаях дают довольно большие p -значения ($p > 0,13$), что также не даёт оснований отвергать гипотезу о нормальности.

Интересно, что критерий Крамера–фон Мизеса (столбец CvM p) для двух выборок (small_mu10_sd2 и mod_mu10_sd2) показывает крайне малые p -значения ($5.2 \cdot 10^{-10}$ и $1.9 \cdot 10^{-7}$ соответственно), формально отвергая нормальность, несмотря на то, что данные были сгенерированы из нормального распределения и графики EDF/QQ не демонстрируют заметных отклонений. Это связано с высокой чувствительностью теста и с тем, что при больших объёмах выборки даже незначительные отклонения от идеальной модели могут приводить к очень малым p -значениям.

6.4 Выводы

- Для всех четырёх выборок, сгенерированных из нормального распределения, графики EDF и QQ (рис. 22–25) показывают хорошее согласование с теоретическим нормальным распределением.
- Большинство используемых тестов (Шапиро–Уилка, Шапиро–Франсиса, Колмогоров–Смирнов, Лиллиефорс, Андерсон–Дарлинг) не отвергают нормальность (p -значения значительно больше 0,05), что согласуется с моделью генерации данных.
- Критерий Крамера–фон Мизеса оказался наиболее чувствительным и для двух выборок формально отверг нормальность.

6.5 Проверка нормальности в R

Аналогично было сделано в R. Были сгенерированы четыре выборки:

- N_100 — выборка объёма $n = 100$ из стандартного нормального распределения;
- N_500 — выборка объёма $n = 500$ из того же распределения;
- Shift_100 — нормальная выборка объёма $n = 100$ со сдвигом среднего;
- HeavyTail — выборка объёма $n = 120$ из распределения с более тяжёлыми хвостами (в отличие от нормального).

Для каждой выборки были построены эмпирические функции распределения и QQ-графики (рис. 26–29).




Рис. 26: EDF и QQ-график для выборки N_{100} ($n = 100$).




Рис. 27: EDF и QQ-график для выборки N_{500} ($n = 500$).




Рис. 28: EDF и QQ-график для выборки Shift_100 ($n = 100$).




Рис. 29: EDF и QQ-график для выборки HeavyTail ($n = 120$).

Для этих выборок были также посчитаны критерии нормальности (Шапиро–Уилка, Шапиро–Франсиа, Андерсона–Дарлингa, Крамера–фон Мизеса и Лиллиефорса). Результаты сведены в табл. 5.

Выборка	n	Shapiro–Wilk p	Shapiro–Franciac p	AD p	CvM p
Lilliefors p					
N_100	100	0.165	0.155	0.253	0.308
0.625					
N_500	500	0.235	0.234	0.103	0.053
0.003					
Shift_100	100	0.251	0.197	0.107	0.084
0.053					
HeavyTail	120	0.00020	0.00023	0.00029	0.00228
0.0134					

Таблица 5: Результаты тестов нормальности для выборок, сгенерированных в R.

По первым трём выборкам (`N_100`, `N_500`, `Shift_100`) EDF и QQ-графики демонстрируют хорошее согласование с теоретическим нормальным распределением: точки на QQ-плотах располагаются вдоль прямой, а эмпирические функции распределения гладко повторяют форму CDF. Это отражается и в результатах тестов: p -значения критериев Шапиро–Уилка, Шапиро–Франсиса, Андерсона–Дарлинга и Крамера–фон Мизеса превышают 0,05, поэтому нулевая гипотеза о нормальности не отвергается. Для выборки `N_500` критерий Лиллиефорса даёт малое p -значение (≈ 0.003), что показывает высокую чувствительность этого теста при большом объёме выборки.

Для выборки `HeavyTail`: на QQ-графике отчётливо видны отклонения в хвостах, а EDF имеет более “крутые” хвосты по сравнению с нормальным распределением. Все рассматриваемые тесты в данном случае дают малые p -значения ($p < 0.01$), однозначно отвергая гипотезу нормальности.

7 Анализ данных с помощью графиков квантилей, метода огибающих и стандартных критериев нормальности

В предыдущем разделе методы проверки нормальности были продемонстрированы на сгенерированных нормальных выборках. Теперь применим те же подходы к реальному признаку `Income` из датасета.

7.1 Выборки и графический анализ

Рассматриваются две выборки по признаку `Income`:

- *малая* выборка размером $n_{\text{small}} = 50$ — доход клиентов с базовым образованием (`Education=Basic`), случайная подвыборка;
- *умеренная* выборка размером $n_{\text{mod}} = 2000$ — случайная подвыборка из всех клиентов с ненулевым доходом.

В Python для каждой выборки построены QQ-графики с 95%-й доверительной огибающей (рис. 30). В малой выборке точки располагаются вдоль прямой и в основном попадают внутрь огибающей, что визуально соответствует нормальному распределению. В умеренной выборке наблюдается сильный уход части точек вверх от прямой (правый хвост), соответствующий наличию выбросов.




Рис. 30: QQ-графики с 95%-й доверительной огибающей для признака `Income`: малая (слева) и умеренная (справа) выборки (Python).

В среде R для тех же выборок построены эмпирические функции распределения и QQ-графики (рис. 31). Для малой выборки `Income | Education=Basic` графики EDF/QQ также указывают на близость к нормальному распределению, тогда как для умеренной выборки виден резкий скачок EDF в области высоких доходов и сильные отклонения точек QQ-графика в правом хвосте.




Рис. 31: EDF и QQ-графики для малой (верхний ряд) и умеренной (нижний ряд) выборок признака `Income` (R).

7.2 Результаты критериев нормальности

В Python для обеих выборок были вычислены значения нескольких критериев нормальности: Шапиро–Уилка (SW), Андерсона–Дарлинга (AD), Крамера–фон Мизеса (CvM), Колмогорова–Смирнова с подогнанными параметрами (KS, fitted μ, σ), Лиллиефорса (LF) и Шапиро–Франсиа (SF). Результаты сведены в табл. 6.

Выборка	n	SW p	AD stat	CvM p	KS p (fit)	LF p	SF p
small	50	0.316	0.545	$5.2 \cdot 10^{-10}$	0.716	0.307	0.366
moderate	2000	$4.2 \cdot 10^{-47}$	16.31	$< 10^{-16}$	$4 \cdot 10^{-6}$	0.001	$5.3 \cdot 10^{-43}$

Таблица 6: Критерии нормальности для признака `Income` (Python).

В среде R для тех же выборок были получены схожие результаты (табл. 7), где приведены p -значения критериев Шапиро–Уилка, Шапиро–Франсиа, Андерсона–Дарлинга, Крамера–фон Мизеса и Лиллиефорса.

Выборка	n	Shapiro–Wilk p	Shapiro–Francis p	AD p	CvM p
Lilliefors p					
small	50	0.229	0.247	0.073	0.053
moderate	2000	$3.8 \cdot 10^{-47}$	$4.9 \cdot 10^{-43}$	$3.7 \cdot 10^{-24}$	$7.4 \cdot 10^{-10}$
		$4.6 \cdot 10^{-18}$			

Таблица 7: Критерии нормальности для признака `Income` (R).

Интерпретация результатов:

- **Малая выборка.** Во всех тестах, кроме CvM в реализации Python, p -значения превышают 0,05. Критерии Шапиро–Уилка, Шапиро–Франсиа, Андерсона–Дарлинга, Колмогорова–Смирнова и Лиллиефорса не отвергают гипотезу нормальности. Это согласуется с QQ-графиками и EDF.
- **Умеренная выборка.** Для выборки из 2000 наблюдений все критерии (SW, AD, CvM, KS, Лиллиефорс, Шапиро–Франсиа) дают малые p -значения ($p \ll 0,05$), однозначно отвергая нормальность. QQ-графика показывают сильный правый хвост и наличие крайне высоких доходов, что соответствует тяжёлому хвосту и существенной асимметрии распределения. При столь большом объёме выборки тесты становятся очень чувствительными.

7.3 Выводы

Совместное использование графических методов (EDF, QQ-графика с огибающими) и стандартных критериев нормальности показало следующее:

- в небольшой, более однородной подвыборке `Income | Education=Basic` распределение дохода можно считать близким к нормальному; тесты нормальности в Python и R дают схожие p -значения и в большинстве своём не отвергают H_0 ;
- в умеренной по размеру выборке из всех клиентов распределение дохода существенно отклоняется от нормального из-за наличия очень высоких доходов; это ясно видно на QQ-графиках, и все критерии нормальности однозначно отвергают гипотезу нормальности.

8 Проверка гипотез

8.1 Теория

Рассматриваем следующие тесты проверки гипотез:

- **t-критерий Стьюдента** для двух независимых выборок используется для проверки равенства средних значений при предположении нормальности распределений и равенства дисперсий. При выполнении условий тест основан на сравнении разности средних с её стандартной ошибкой; возможны двусторонняя и односторонние варианты.
- **Критерий Манна–Уитни** (Уилкоксона–Манна–Уитни) непараметрический аналог t-теста, сравнивающий ранги наблюдений в двух независимых группах. Не требует нормальности, устойчив к выбросам и фактически проверяет гипотезу о совпадении распределений.
- **Критерии равенства дисперсий.** Для двух групп часто используют F-критерий Фишера; для нескольких групп — тест Бартлетта. Оба предполагают нормальность и чувствительны к выбросам. Более робастные альтернативы тест Левена и ранговый тест Флигнера–Килина, которые допускают отклонения от нормальности (но Левен всё ещё чувствителен к сильным выбросам).

8.2 t-критерий

Рассматривается признак `Income` и бинарный отклик на маркетинговую кампанию `Response` (0 — не откликнулся, 1 — откликнулся). После удаления пропусков размеры групп составили:

$$n_0 = 1883 \text{ (Response = 0)}, \quad n_1 = 333 \text{ (Response = 1)}.$$

На исходных данных проверка нормальности по критерию Шапиро–Уилка показала значимые отклонения от нормального распределения в обеих группах ($p \ll 0,05$), а тест Левена выявил неодинаковость дисперсий ($p \approx 0.012$), поэтому прямое применение t-критерия некорректно. Гистограммы и QQ-графики исходного дохода демонстрируют выраженный правый хвост.

Чтобы приблизить данные к условиям применимости t-теста, было выполнено:

1. логарифмирование дохода: `LogIncome = log(Income + 1)`;
2. отсечение крайних 1% значений `LogIncome` (по квантилям 1% и 99%).

После этого в выборках осталось $n_0 = 1849$ и $n_1 = 321$ наблюдений. Гистограммы и QQ-графики лог-дохода (рис. 32) показывают близость распределений к нормальным в обеих группах: существенных отклонений в центральной части не видно, различия в хвостах имеют сходный характер. Тест Левена для лог-дохода после отсечения не выявил существенных различий дисперсий ($p \approx 0.55$), что позволяет применить классический t-критерий с предположением равенства дисперсий.




Рис. 32: Сравнение лог-дохода по группам **Response**: гистограммы и QQ-графики.

Далее был проведён двусторонний t-тест для логарифма дохода:

$$H_0 : \mu_0 = \mu_1, \quad H_1 : \mu_0 \neq \mu_1,$$

где μ_0 и μ_1 — математические ожидания **LogIncome** в группах **Response=0** и **Response=1** соответственно.

Результаты:

$$t = -5.90, \quad p \approx 4.3 \cdot 10^{-9}.$$

Односторонние варианты дали:

$H_1 : \mu_1 > \mu_0 \Rightarrow p \approx 1.0$ (гипотеза не поддерживается),

$H_1 : \mu_1 < \mu_0 \Rightarrow p \approx 2.1 \cdot 10^{-9}$ (значимое уменьшение лог-дохода в группе **Response = 1**).

Доверительные интервалы для разности средних (в шкале лог-дохода $\mu_0 - \mu_1$) составили:

90% ДИ: [0.1145; 0.2031],

95% ДИ: [0.1060; 0.2116],

99% ДИ: [0.0894; 0.2282].

Оценка размера эффекта (d Коэна) $d \approx 0.36$, что соответствует *умеренной* силе эффекта. При текущем объёме выборок расчётная мощность теста близка к 1; при $n \approx 125$ на группу мощность t-теста достигала бы ≈ 0.8 при том же эффекте.

8.3 Критерий Уилкоксона-Манна-Уитни

Был применён критерий Уилкоксона-Манна-Уитни к *исходным* данным по доходу (без лог-преобразования и отсечения):

$$n_0 = 1883, \quad n_1 = 333.$$

Двусторонний тест

H_0 : распределения дохода в группах одинаковы, H_1 : распределения различаются
дал статистику

$$U = 231\,913.5, \quad p \approx 3.4 \cdot 10^{-14},$$

так что при уровнях значимости $\alpha = 0.1, 0.05, 0.01$ нулевая гипотеза отвергается.

При односторонней альтернативе

$$H_1 : \text{доход в группе Response=1 выше, чем в Response=0}$$

получено $p \approx 1.7 \cdot 10^{-14}$ (отклонение H_0 на всех трёх уровнях), тогда как противоположная направленность

$$H_1 : \text{доход в группе Response=1 ниже}$$

не подтверждается ($p \approx 1$). Это согласуется с тем, что распределение дохода откликнувшихся клиентов смещено в сторону больших значений.

8.4 Проверка равенства дисперсий

Для сравнения дисперсий лог-дохода в группах по **Response** использован F-критерий Фишера на подготовленных данных (лог-преобразование и отсечение 1% хвостов). Проверялись гипотезы:

$$H_0 : \sigma_0^2 = \sigma_1^2, \quad H_1 : \sigma_0^2 \neq \sigma_1^2.$$

Получено

$$F = 1.07, \quad p \approx 0.43,$$

то есть при $\alpha = 0.1, 0.05, 0.01$ гипотеза о равенстве дисперсий *не* отвергается.

Для трёх наиболее крупных категорий семейного статуса (**Married**, **Together**, **Single**) проводились тесты Бартлетта и Левена.

- **Тест Бартлетта** на лог-доходе (после отсечения хвостов) дал

$$\chi^2 \approx 4.94, \quad p \approx 0.084.$$

При $\alpha = 0.1$ гипотеза о равенстве дисперсий отвергается, при более строгих уровнях $\alpha = 0.05, 0.01$ — нет. Voxplot соответствующих групп показан на рис. 33.

- **Тест Левена** на исходном доходе для тех же трёх категорий показал

$$F \approx 1.05, \quad p \approx 0.35,$$

то есть при $\alpha = 0.1, 0.05, 0.01$ оснований считать дисперсии различными нет (рис. 34).

- **Тест Флигнера–Килина** Тест Флигнера–Килина был применён к тем же трём группам по семейному статусу (*Married*, *Together*, *Single*). По результатам p -значение оказалось больше 0,05, то есть на стандартных уровнях значимости нет оснований отвергать гипотезу о равенстве дисперсий между этими группами. Это указывает на то, что различия разброса доходов по основным категориям семейного статуса статистически несущественны.




Рис. 33: Boxplot лог-дохода по семейному статусу и результат теста Бартлетта.




Рис. 34: Boxplot дохода по семейному статусу и результат теста Левена.

8.5 Выводы

- Исходное распределение дохода сильно асимметрично с тяжёлым правым хвостом; для применения t -критерия Стьюдента потребовались логарифмирование и отсеечение крайних 1% значений.

- После преобразований распределения лог-дохода в группах по **Response** стали близки к нормальным, а дисперсии — приблизительно равными, что позволило использовать t-критерий.
- t-тест показал статистически значимое различие средних лог-доходов между откликнувшимися и неоткликнувшимися клиентами, с умеренным размером эффекта (d Коэна ≈ 0.36) и очень высокой мощностью теста.
- Критерий Уилкоксона-Манна-Уитни на исходных данных по доходу подтвердил, что распределение дохода в группе **Response=1** смещено в сторону больших значений: доход откликнувшихся клиентов статистически выше дохода неоткликнувшихся.
- Проверка равенства дисперсий в различных группах (по отклику и по семейному статусу) показала, что в большинстве случаев различия дисперсий либо отсутствуют, либо проявляются на мягком уровне значимости $\alpha = 0.1$.

9 Корреляционные взаимосвязи

9.1 Теория

Для количественных признаков зависимость между переменными удобно описывать коэффициентами корреляции. В работе используются три меры:

- **Корреляция Пирсона** измеряет силу *линейной* связи между двумя числовыми признаками. Корректно интерпретируется при примерно нормальных распределениях и отсутствии сильных выбросов.
- **Корреляция Спирмена** представляет собой обычную корреляцию Пирсона, но посчитанную по ранговым значениям. Характеризует *монотонную* (не обязательно линейную) связь и более устойчива к выбросам и асимметрии распределений.
- **Корреляция Кендалла** также основана на рангах и подсчёте согласованных/несогласованных пар наблюдений. Её удобно использовать при небольшом числе наблюдений или при наличии большого количества совпадающих значений; она ещё более робастна, чем корреляция Спирмена.

Во всех случаях коэффициент лежит в интервале $[-1; 1]$; по модулю значения ближе к 1 соответствуют более сильной (положительной или отрицательной) связи.

9.2 Матрицы корреляций

Для анализа взаимосвязей были рассмотрены следующие числовые признаки:

Year_Birth, Income, Kidhome, Teenhome, Recency,
MntWines, MntFruits, MntMeatProducts, MntFishProducts,
MntSweetProducts, MntGoldProds, NumDealsPurchases, NumWebPurchases,
NumCatalogPurchases, NumStorePurchases, NumWebVisitsMonth.

По этим столбцам были вычислены матрицы корреляций Пирсона, Спирмена и Кендалла. На рис. 35 показаны тепловые карты, построенные в Python, а на рис. 36 аналогичные карты, полученные в R; качественно результаты совпадают.




Рис. 35: Матрицы корреляций Пирсона, Спирмена и Кендалла (Python).




Рис. 36: Матрицы корреляций по тем же признакам, рассчитанные в R.

9.3 Наиболее сильные взаимосвязи

Для интерпретации рассмотрим пары признаков с наибольшей по модулю корреляцией.

Пирсон. Топ-10 пар с наибольшей линейной связью:

1. MntMeatProducts — NumCatalogPurchases: $r = 0.734$;
2. MntWines — NumStorePurchases: $r = 0.640$;
3. MntWines — NumCatalogPurchases: $r = 0.635$;
4. MntFruits — MntFishProducts: $r = 0.593$;
5. Income — NumCatalogPurchases: $r = 0.589$;
6. Income — MntMeatProducts: $r = 0.585$;
7. MntFishProducts — MntSweetProducts: $r = 0.584$;
8. Income — MntWines: $r = 0.579$;
9. MntMeatProducts — MntFishProducts: $r = 0.574$;
10. MntFruits — MntSweetProducts: $r = 0.572$.

Спирмен. Топ-10 ранговых корреляций:

1. MntMeatProducts — NumCatalogPurchases: $\rho = 0.854$;
2. Income — MntWines: $\rho = 0.830$;
3. MntWines — MntMeatProducts: $\rho = 0.824$;
4. MntWines — NumCatalogPurchases: $\rho = 0.823$;
5. Income — MntMeatProducts: $\rho = 0.817$;
6. MntWines — NumStorePurchases: $\rho = 0.805$;
7. Income — NumCatalogPurchases: $\rho = 0.792$;
8. MntMeatProducts — NumStorePurchases: $\rho = 0.780$;
9. MntWines — NumWebPurchases: $\rho = 0.742$;
10. Income — NumStorePurchases: $\rho = 0.732$.

Кендалл. Топ-10 корреляций τ :

1. MntMeatProducts — NumCatalogPurchases: $\tau = 0.686$;
2. MntWines — NumCatalogPurchases: $\tau = 0.646$;
3. Income — MntWines: $\tau = 0.633$;
4. MntWines — NumStorePurchases: $\tau = 0.621$;
5. MntWines — MntMeatProducts: $\tau = 0.620$;
6. Income — MntMeatProducts: $\tau = 0.619$;
7. Income — NumCatalogPurchases: $\tau = 0.619$;
8. MntMeatProducts — NumStorePurchases: $\tau = 0.596$;
9. MntWines — NumWebPurchases: $\tau = 0.571$;
10. MntFruits — MntFishProducts: $\tau = 0.550$.

9.4 Выводы

- Клиенты, которые много тратят на вино и мясные продукты (MntWines, MntMeatProducts), как правило, активно покупают через каталог, в розничном магазине и онлайн (NumCatalogPurchases, NumStorePurchases, NumWebPurchases).
- Доход (Income) сильно связан с расходами на основные товарные категории и с количеством покупок: чем выше доход, тем больше суммарные траты (особенно на вино и мясо).
- Категории товаров ведут себя согласованно: траты на фрукты, рыбу и сладости (MntFruits, MntFishProducts, MntSweetProducts) положительно коррелируют между собой, что характерно для общего “уровня потребления”.

- Значения корреляций Спирмена и Кендалла, как правило, выше, чем коэффициенты Пирсона для тех же пар признаков. Это говорит о том, что зависимости преимущественно монотонные, но не строго линейные, а также подчёркивает устойчивость ранговых мер к выбросам.

10 Метод χ^2 , точный тест Фишера, тест МакНемара и критерий Кохрана–Мантеля–Хензеля

10.1 Теория

Для категориальных признаков используются следующие критерии:

- **Тест независимости χ^2** применяется к таблицам сопряжённости (обычно $r \times c$), чтобы проверить гипотезу

$$H_0 : \text{признаки независимы}, \quad H_1 : \text{между признаками есть ассоциация}.$$

Статистика сравнивает наблюдаемые частоты с ожидаемыми при независимости и асимптотически имеет распределение χ^2 .

- **Точный тест Фишера** используется для 2×2 -таблиц, особенно при малых ожидаемых частотах. Вместо асимптотики учитывается точное гипергеометрическое распределение, что даёт корректные p -значения даже при очень маленьких выборках.
- **Тест МакНемара** предназначен для парных бинарных наблюдений (например, до/после, две кампании для одного клиента). Рассматривается таблица переходов « $0 \rightarrow 0$, $0 \rightarrow 1$, $1 \rightarrow 0$, $1 \rightarrow 1$ », и проверяется гипотеза о равенстве долей «успехов» в двух условиях:

$$H_0 : p_1 = p_2, \quad H_1 : p_1 \neq p_2.$$

Статистика строится по несоответствующим парам (0,1) и (1,0).

- **Критерий Кохрана–Мантеля–Хензеля (СМН)** обобщает анализ 2×2 -таблиц на случай стратификации по третьему признаку. Рассматривается набор 2×2 -таблиц по стратам, и тест проверяет гипотезу о независимости двух бинарных признаков при фиксированном уровне фактора (условной независимости).

10.2 Тест χ^2

Рассмотрим таблицу сопряжённости для признаков `Marital_Status` и `Response` (табл. 8). Тепловая карта частот приведена на рис. 37.

<code>Marital_Status</code>	<code>Response=0</code>	<code>Response=1</code>
Absurd	1	1
Alone	2	1
Divorced	184	48
Married	766	98
Single	374	106
Together	520	60
Widow	58	19
YOLO	1	1

Таблица 8: Таблица сопряжённости `Marital_Status` $\times$ `Response`.




Рис. 37: Тепловая карта частот $\text{Marital_Status} \times \text{Response}$.

Для этой таблицы статистика χ^2 и p -значение составили

$$\chi^2 = 54.24, \quad p < 0.0001.$$

На всех рассмотренных уровнях значимости $\alpha = 0.1, 0.05, 0.01$ нулевая гипотеза независимости отвергается. Следовательно, семейное положение статистически связано с откликом на кампанию.

10.3 Точный тест Фишер

Далее анализировалась связь между бинарными признаками Complain (наличие жалоб) и Response . Таблица 2×2 имеет вид (табл. 9 и рис. 38):

	Response=0	Response=1
Complain=0	1888	331
Complain=1	18	3

Таблица 9: Таблица сопряжённости $\text{Complain} \times \text{Response}$.



Рис. 38: Тепловая карта $\text{Complain} \times \text{Response}$.

Точный тест Фишера дал

$$\text{odds ratio} \approx 0.95, \quad p = 1.0.$$

На уровнях $\alpha = 0.1, 0.05, 0.01$ нет оснований отвергать H_0 : жалобы клиентов и отклик на рассматриваемую кампанию статистически независимы.

10.4 Тест МакНемара: отклики на кампании 1 и 2

Для одного и того же множества клиентов рассмотрены бинарные признаки `AcceptedCmp1` и `AcceptedCmp2` (принятие кампаний 1 и 2). Парная таблица имеет вид (табл. 10, рис. 39):

	<code>AcceptedCmp2=0</code>	<code>AcceptedCmp2=1</code>
<code>AcceptedCmp1=0</code>	2079	17
<code>AcceptedCmp1=1</code>	131	13

Таблица 10: Таблица для теста МакНемара: `AcceptedCmp1` vs `AcceptedCmp2`.




Рис. 39: Тепловая карта `AcceptedCmp1` × `AcceptedCmp2`.

Тест МакНемара дал

$$\chi^2_{\text{McN}} = 17.0, \quad p < 0.0001.$$

На всех уровнях значимости нулевая гипотеза о равенстве долей откликов на кампании 1 и 2 отвергается: вероятность принятия второй кампании значимо отличается от первой (по таблице видно, что клиентов, принявших кампанию 1, но не принявших кампанию 2, существенно больше, чем наоборот).

10.5 Критерий Кохрана–Мантеля–Хензеля

Наконец, была исследована связь между `Complain` и `Response` с учётом количества маленьких детей в домохозяйстве (`Kidhome`). Для каждого значения `Kidhome` (0, 1, 2) строилась отдельная таблица 2×2 (рис. 40), а затем применён критерий Кохрана–Мантеля–Хензеля.




Рис. 40: Таблицы `Complain` × `Response` в стратах по `Kidhome`.

Стратифицированный тест СМН дал

$$\chi^2_{\text{СМН}} \approx 0.0056, \quad p \approx 0.94.$$

При $\alpha = 0.1, 0.05, 0.01$ нулевая гипотеза условной независимости **Complain** и **Response** не отвергается: даже после учёта количества детей ассоциации между этими признаками не обнаружено.

10.6 Выводы

- Семейное положение (**Marital_Status**) статистически связано с откликом на кампанию (**Response**), что подтверждено тестом χ^2 .
- Наличие жалоб (**Complain**) не демонстрирует значимой связи с откликом ни в общей выборке (точный тест Фишера), ни при учёте количества детей (критерий Кохрана–Мантеля–Хензеля).
- Отклики на маркетинговые кампании 1 и 2 существенно различаются: тест МакНемара показывает, что доли принявших кампанию изменились, причём кампания 2 была принята заметно реже, чем первая.

11 Мультиколлинеарность в данных

11.1 Теория

Мультиколлинеарность возникает, когда несколько переменных сильно коррелируют друг с другом. В регрессионных моделях это приводит к росту дисперсий оценок коэффициентов и нестабильности. Для оценки мультиколлинеарности используют:

- матрицы корреляций (для грубой оценки связей между парами признаков);
- *фактор инфляции дисперсии* (**VIF**), который измеряет, во сколько раз увеличивается дисперсия оценки коэффициента из-за линейной зависимости с другими признаками. В качестве порогов рассматривают значения $VIF > 5$ (заметная мультиколлинеарность) и $VIF > 10$ (сильная).

11.2 Результаты

Ранее были построены матрицы корреляций Пирсона, Спирмена и Кендалла. Для анализа мультиколлинеарности далее используем коэффициент Спирмена, так как он устойчив к выбросам и лучше отражает монотонные, а не строго линейные зависимости. На рис. 41 показана тепловая карта корреляций Спирмена по числовым признакам.




Рис. 41: Корреляции Спирмена между числовыми признаками.

Для расчёта VIF признаки предварительно были преобразованы (учёт переко-
сов распределений и выбросов), после чего получены следующие значения фактора
инфляции дисперсии:

Признак	VIF
MntMeatProducts	7.82
MntWines	7.80
Income	4.43
NumCatalogPurchases	2.89
MntFishProducts	2.74
NumWebPurchases	2.73
MntFruits	2.71
NumWebVisitsMonth	2.64
MntSweetProducts	2.59
NumStorePurchases	2.56
Kidhome	2.07
MntGoldProds	1.91
NumDealsPurchases	1.87
Teenhome	1.85
Year_Birth	1.26
Recency	1.01

Таблица 11: Факторы инфляции дисперсии (VIF) для числовых признаков.

11.3 Выводы

- Наиболее высокие значения VIF наблюдаются у признаков **MntMeatProducts** и **MntWines** ($VIF \approx 7.8$), что говорит о заметной мультиколлинеарности этих расходов с другими покупательскими переменными.
- Доход **Income** также существенно коррелирует с другими признаками ($VIF \approx 4.4$).

- Для остальных переменных VIF находится в умеренном диапазоне ($\approx 1-3$), сильной мультиколлинеарности не наблюдается.

12 Дисперсионный анализ

12.1 Теория

Дисперсионный анализ (ANOVA) используется для проверки равенства средних значений количественного признака в нескольких группах. В случае однофакторного анализа с фактором A (например, уровни образования) проверяются гипотезы

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_k, \quad H_1 : \exists i, j : \mu_i \neq \mu_j,$$

где μ_i — средний отклик в группе i . Статистика F сравнивает межгрупповую вариацию с внутригрупповой; при верной H_0 она имеет распределение Фишера.

ANOVA предполагает приблизительную нормальность распределения отклика в группах, одинаковость дисперсий и независимость наблюдений. Тест чувствителен к выбросам, поэтому перед анализом иногда выполняют преобразования логарифмирование и отсечение крайних значений.

12.2 Результаты

В качестве отклика использовали логарифм дохода $\text{LogIncome} = \log(\text{Income} + 1)$. Для уменьшения влияния выбросов были отброшены наблюдения за пределами 1-го и 99-го перцентилей LogIncome , в итоге осталось 2170 наблюдений.

Для наглядности построены boxplot-диаграммы лог-дохода по семейному статусу и уровню образования (рис. 42–43).




Рис. 42: Распределение LogIncome по категориям Marital_Status .




Рис. 43: Распределение LogIncome по уровням Education.

Проверялись две совокупности гипотез:

- для семейного статуса:

H_0 : средний LogIncome одинаков для всех категорий Marital_Status,

H_1 : хотя бы в одной категории средний LogIncome отличается;

- для образования:

H_0 : средний LogIncome одинаков для всех уровней Education,

H_1 : существует уровень образования с отличающимся средним доходом.

Однофакторный ANOVA дал следующие результаты:

LogIncome ~ Marital_Status : $F(7, 2162) = 1.55$, $p \approx 0.147$;

LogIncome ~ Education : $F(4, 2165) = 63.41$, $p \approx 9.5 \cdot 10^{-51}$.

Также была построена двухфакторная модель

$\text{LogIncome} \sim C(\text{Education}) + C(\text{Marital_Status})$,

для которой ANOVA (тип II) показал:

$C(\text{Education})$: $F(4, 2158) = 62.46$, $p \approx 5.3 \cdot 10^{-50}$;

$C(\text{Marital_Status})$: $F(7, 2158) = 1.16$, $p \approx 0.32$.

Краткие выводы

- После логарифмирования дохода и отсеечения крайних 1% наблюдений: распределения внутри групп близки к симметричным, выбросы ограничены.
- Однофакторный анализ показал, что **семейное положение** не оказывает статистически значимого влияния на логарифм дохода ($p \approx 0.15$), тогда как **уровень образования** имеет очень сильный эффект ($p \ll 0.001$).
- В двухфакторной модели значимым остаётся только фактор **Education**, а вклад **Marital_Status** остаётся статистически несущественным. Это показывает, что различия в доходах клиентов в первую очередь обусловлены уровнем образования, а не семейным статусом.

13 Регрессионные модели (в том числе нелинейные)

13.1 Теория

Регрессионный анализ позволяет моделировать зависимость количественного признака-отклика Y (в нашем случае `LogIncome`) от набора объясняющих переменных $X_1, \dots, X_p$.

- **Множественная линейная регрессия** предполагает модель

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p + \varepsilon,$$

где ε — случайная ошибка. Модель хорошо описывает зависимости, близкие к линейным, и даёт коэффициенты с простой интерпретацией.

- **Полиномиальная регрессия** расширяет базис за счёт нелинейных преобразований признаков (квадраты, попарные произведения и т.п.). Формально это остаётся линейной моделью по параметрам, но позволяет приближать слабонелинейные зависимости между Y и X .

Качество моделей оценивается по коэффициенту R^2 (доля объяснённой дисперсии), средней абсолютной ошибке (MAE) и квадратичному отклонению (RMSE).

13.2 Подготовка данных и постановка задачи

В качестве целевой переменной использовался логарифм дохода

$$\text{LogIncome} = \log(\text{Income} + 1),$$

чтобы уменьшить асимметрию распределения и влияние выбросов. Далее были отброшены наблюдения с `LogIncome` вне интервала между 1-м и 99-м перцентилями. После подготовки осталось 2170 наблюдений.

В модель включались только числовые признаки, не связанные напрямую с целевой переменной и маркетинговыми откликами:

В анализ были включены следующие количественные признаки: `Year_Birth`, `Kidhome`, `Teenhome`, `Recency`, `MntWines`, `MntFruits`, `MntMeatProducts`, `MntFishProducts`, `MntSweetProducts`, `MntGoldProds`, `NumDealsPurchases`, `NumWebPurchases`, `NumCatalogPurchases`, `NumStorePurchases`, `NumWebVisitsMonth`.

В итоге матрица признаков имела размер 2170×15 .

Были обучены две модели:

1. множественная линейная регрессия по исходным признакам;
2. полиномиальная регрессия второй степени (включены квадраты).

13.3 Результаты моделирования

Сводные метрики качества:

Модель	R^2	MAE	RMSE
Линейная регрессия	0.73	0.173	0.237
Полиномиальная регрессия	0.81	0.143	0.199

Таблица 12: Качество моделей прогнозирования LogIncome.

Коэффициент детерминации $R^2 \approx 0.73$ для линейной модели означает, что около 73% вариации логарифма дохода объясняется выбранными количественными признаками. Добавление квадратичных членов увеличивает R^2 до 0.81 и улучшает ошибки MAE и RMSE.

На рис. 44 приведено сравнение фактических и прогнозных значений LogIncome для обеих моделей: точки полиномиальной регрессии лежат ближе к диагонали, чем точки линейной модели.




Рис. 44: Фактические и прогнозные значения LogIncome для линейной и полиномиальной регрессий.

13.4 Выводы

- Набор количественных признаков (возраст, структура домохозяйства, давность покупки и объёмы расходов по категориям и каналам) позволяет достаточно хорошо объяснять вариацию логарифма дохода.

- Линейная модель уже даёт приемлемое качество ($R^2 \approx 0.73$), однако добавление квадратичных и взаимодействующих терминов заметно улучшает результаты ($R^2 \approx 0.81$, снижение MAE и RMSE).
- Это свидетельствует о наличии слабой нелинейности в связи между признаками и `LogIncome`: зависимость не полностью линейна, и полиномиальная регрессия описывает данные лучше, чем простая линейная.

Список литературы

- [1] Брюс П., Брюс Э., Гедек П. *Практическая статистика для специалистов Data Science*. – 2-е изд., перераб. и доп. – СПб.: БХВ-Петербург, 2021. – 352 с.
- [2] Мастицкий С.Э., Шитиков В.К. *Статистический анализ и визуализация данных с помощью R*. – М.: ДМК Пресс, 2015. – 496 с.
- [3] Нильсен Э. *Практический анализ временных рядов: прогнозирование со статистикой и машинное обучение*. – СПб.: ООО «Диалектика», 2021. – 544 с.